



Instituto Tecnológico y de Estudios Superiores de Monterrey

Analítica de datos y herramientas de inteligencia artificial II (Gpo 101)

Actividad AG_1.1 y 1.2 (Extracción de Características)

Docente:

Alfredo García Suárez

Autor:

Laisha Fernanda Puentes Angulo - A01736397

Mauricio Grau Gutiérrez Rubio -A01734914

Fecha: Septiembre 26

1. Preprocesamiento de datos

Antes de iniciar el análisis, se revisaron los valores nulos en todas las columnas, las variables numéricas como Abundance_nbcell, TotalAbundance_SamplingOperation y Abundance_pm presentaban valores nulos, estos valores pueden distorsionar los resultados si se eliminan o se ignoran, por ello, se optó por aplicar una estrategia de imputación:

- Para variables de texto se asignó el valor "sin_dato" a los registros vacíos, evitando que se pierdan filas completas.
- Para variables numéricas se utilizó la mediana, ya que es menos sensible a valores atípicos en comparación con el promedio.

Esta decisión asegura que la base de datos mantenga la mayor cantidad de información posible y que las medidas de tendencia central no se vean afectadas por datos extremos, después de este proceso, no quedaron valores nulos en el dataset.

2. Detección y tratamiento de outliers

Se utilizaron boxplots para identificar valores atípicos en las variables numéricas, estos gráficos permitieron visualizar de forma rápida los valores que se alejaban mucho de la mayoría de los datos, posteriormente, se calcularon límites usando la fórmula $\text{media} \pm 3$ desviaciones estándar para cada variable, los valores por encima del límite superior o por debajo del límite inferior se consideraron outliers y se ajustaron para que no distorsionaran la distribución de los datos.

Al tratar los outliers se evita que estos valores extremos generen sesgos en estadísticas como la media y en modelos que se construyan más adelante. Esto permite trabajar con una base más representativa.

3. Análisis univariado de variables categóricas

Se analizaron las columnas TaxonName, TaxonCode, SamplingOperations_code y Date_SamplingOperation, para cada variable se generaron tablas de frecuencias y gráficas de barras de las categorías más comunes.

Principales hallazgos:

- En TaxonName, las especies Achnanthes minutissima y Amphora pediculus fueron las más frecuentes, representando un porcentaje considerable de todos los registros.
- En TaxonCode se observó que la mayoría de los registros se concentran en unos pocos códigos, lo que sugiere una baja diversidad en los datos.

- En SamplingOperations_code hubo códigos que aparecieron de manera recurrente, indicando que ciertos muestreos fueron mucho más extensos o productivos.
- En Date_SamplingOperation se identificaron picos en ciertos años, lo que podría relacionarse con campañas de recolección de datos más intensivas en esos periodos.

El análisis univariado es clave para entender la composición de la base de datos, la concentración en pocos taxones y códigos de muestreo puede influir en futuros análisis ecológicos y de diversidad.

4. Categorización de variables numéricas (Regla de Sturges)

Las variables numéricas fueron agrupadas en intervalos utilizando la Regla de Sturges, que sugiere el número de bins adecuado para representar una distribución en un histograma.

Resultados:

- Para Abundance_nbcell se generaron 22 intervalos y se observó que la mayor parte de los datos se concentró en los primeros intervalos, indicando que la mayoría de las observaciones tienen baja abundancia de células.
- TotalAbundance_SamplingOperation mostró una distribución más amplia, pero igualmente con acumulación de valores en los intervalos bajos.
- Abundance_pm presentó también una concentración en los primeros grupos, mostrando un patrón de sesgo a la izquierda.

Esta categorización permite identificar patrones y comparar fácilmente los resultados entre diferentes sitios de muestreo, el sesgo a la izquierda puede indicar que las condiciones ecológicas favorecen bajos niveles de abundancia en la mayoría de los casos, pero con algunos pocos sitios con abundancias mucho más altas.

5. Dataset final

Después del preprocesamiento y la categorización se obtuvo un dataset limpio, sin valores nulos ni atípicos extremos, este conjunto de datos es ideal para análisis estadísticos más avanzados o modelos de machine learning.

En conclusión la calidad del dataset mejoró considerablemente después de aplicar técnicas de imputación y tratamiento de outliers, el análisis univariado permitió detectar las especies dominantes y los años de mayor muestreo, información valiosa para interpretar resultados ecológicos y planificar futuras investigaciones.